

# AWI-ESM3-4-2-veg-HR, CMIP7 piControl

Was sich seit cli112 geaendert hat, und Antwort auf deine letzten drei Runden

Jan Streffing, AWI

17. August 2026

## 1 Kurzfassung

Seit cli112 sind drei Runden von dir eingegangen: der Koordinaten-Check, die Liste mit den acht Punkten, und dein Plugin. Zusammen mit dem, was das Plugin selbst noch gefunden hat, waren das rund zwanzig Befunde. Umfang seither: 15 Commits, 26 Dateien, +1197 / -209 Zeilen.

Der Zwischenstand an harten Zahlen, gemessen an cli114:

|        | cli113 | cli114 |
|--------|--------|--------|
| HIGH   | 69     | 1      |
| MEDIUM | 288    | 284    |

Das verbleibende HIGH ist weiterhin `basin` und wartet auf `ESGF/cc-plugin-wcrp#67`. cli115 laeuft gerade und enthaelt alles aus diesem Dokument; die Gegenprobe schicken wir nach.

## 2 Dein Plugin

`cc-plugin-aicc` laeuft ab sofort in jedem unserer Laeufe mit, als dritte Suite neben `cf` und `wcrp_cmip7`. Das war die wirksamste einzelne Aenderung dieser Runde: er sieht eine ganze Klasse, die die beiden anderen nicht anfassen. 41 Dateien mit `latitude(latitude)` statt `lat(lat)` sind an `cf` und `wcrp_cmip7` glatt vorbeigelaufen.

Ein Hinweis dazu, den du vermutlich wissen willst. Ohne gesetztes `CMIP7_TABLES_PATH` wirft das Plugin eine `FileNotFoundError` aus `ComplianceChecker.run_checker` heraus, und damit stirbt der gesamte `cchecker`-Aufruf:

|                                     | Exit | Report           |
|-------------------------------------|------|------------------|
| ohne <code>CMIP7_TABLES_PATH</code> | 1    | gar keiner       |
| mit <code>CMIP7_TABLES_PATH</code>  | 1    | alle drei Suiten |

Es fehlt also nicht nur das `aicc`-Ergebnis, sondern auch das von `cf` und `wcrp_cmip7` fuer dieselbe Datei. Bei uns waere das lautlos gewesen: `pymor` protokolliert, dass kein JSON entstand, und laeuft weiter. Eine Datei ohne Sidecar wird nirgends gezaehlt, der Lauf haette also sauberer ausgesehen als vorher. Wir pruefen den Pfad deshalb jetzt einmal beim Submit, statt es nach ein paar hundert Dateien zu merken. Vielleicht ist ein Befund statt einer Exception fuer dich der bessere Weg.

### 3 Deine acht Punkte

#### 1. Verlustbehaftete Kompression auf `ps`

**erledigt** Du hast recht, und die entscheidende Stelle ist der Zusatz in CF: nicht nur Koordinaten, sondern auch eine Variable, die von `coordinates`, `formula_terms` oder `cell_measures` benannt wird, "even if it is also a data variable". Genau den hatten wir uebersehen. Im Code stand woertlich:

```
# ps is a genuine geophysical field and keeps its normal treatment.
```

Das stimmt fuer sich genommen, nur greift die Ausnahme eben trotzdem, weil `ps` zugleich `formula_term` der Hybridachse ist. Betraf 9 Dateien. Wir sammeln die geschuetzten Variablen jetzt nach der Regel statt `ps` einzeln auszunehmen. Nachgemessen war `ps` in `cli114` tatsaechlich der einzige Treffer.

#### 2. `plev`: positive und units

**erledigt** Und der Fund war groesser, als er aussieht. Es war kein Fehler an `plev` allein, sondern an allen Vertikalachsen ausser `lev`: der Pass, der die CV-Werte durchsetzt, kannte nur `lev`.

| Achse               | was falsch war                                                                                                   | Dateien |
|---------------------|------------------------------------------------------------------------------------------------------------------|---------|
| <code>plev</code>   | <code>standard_name</code> und <code>axis</code> fehlen, <code>units</code> "pascal", <code>positive</code> "up" | 17      |
| <code>height</code> | <code>axis</code> fehlt                                                                                          | 35      |
| <code>sdepth</code> | <code>units</code> "meter"                                                                                       | 3       |

Sichtbar wurde es erst, als die Achse richtig `plev` hiess. Solange sie `plev19` oder `plev3` hiess, lief der Check ins Leere, weil er eine Variable namens `plev` sucht. In `cli112` standen also 68 HIGH latent im Output, ohne dass sie jemand zaehlte.

Dazu der Typ: `plev` lag als `float32` vor, die Tabelle sagt `double` (17 Dateien), `sdepth` als `int64`. Wird jetzt aus dem `type`-Feld der Tabelle abgeleitet.

#### 3. `alevel`: `lev`, `a`, `b` invertieren

**erledigt** `stored_direction` ist "decreasing", die ECMWF-Vertikaltabelle laeuft top-first, also kam bei uns alles aufsteigend heraus. Gedreht wird die ganze Achse in einem Zug, nicht nur die Koordinate, damit die Daten an ihrem Level haengen bleiben. Das ist die einzige Aenderung dieser Runde, die Werte bewegt, deshalb gegen die echten L137-Koeffizienten geprueft:

|                       | vorher              | nachher                         |
|-----------------------|---------------------|---------------------------------|
| <code>lev</code>      | 1,00e-05 ... 0,9988 | 0,9988 ... 1,00e-05             |
| <code>b</code>        | 0 ... 0,9988        | 0,9988 ... 0                    |
| $p = ap + b \cdot ps$ | steigend            | 100880 ... 1 Pa, streng fallend |
| Testfeld 0 ... 136    | 0 ... 136           | 136 ... 0                       |

Die Bounds-Paare drehen mit, sonst stuende in jeder Zelle weiter [unten, oben]. `ap` und `b` haben ausserdem das `(k)` im `long_name` verloren.

#### 4. `deltasigt` mit Absatz im `long_name`

**erledigt** Der Absatz steht schon upstream im `long_name`, rund 900 Zeichen Methodenbeschreibung mit Literaturangaben. Wir kuerzen jetzt auf den ersten Satz und verschieben den ganzen Text nach `comment`. Das greift generisch, nicht nur bei `deltasigt`.

Gleich mit erledigt: die `long_name` aller Koordinaten kommen jetzt aus der Tabelle, und zwar ueber den DReq-Namen, nicht ueber den Ausgabenamen. `plev19` heisst "Pressure Levels (19)"

und `plev3` "Pressure Levels (3)", geschrieben werden beide als `plev`. Bei `time` genauso, das sind vier verschiedene Werte auf derselben Achse. Betraf 492 Dateien.

## 5. Bodentiefe ohne Bounds, `slthick` ohne Gitter

**erledigt** Beides.

Bei `sdepth10cm` liefert die Tabelle die Bounds sogar mit (`bounds_values` "0.0 10.0"), wir haben sie nur nicht gelesen und geschrieben allein den Mittelpunkt 5,0 cm. Die Schicht, fuer die der Wert steht, stand also gar nicht in der Datei.

`slthick` kam als `slthick(sdepth)` heraus, ein 1D-Feld, dessen Koordinate der Schichtindex 1..4 war statt einer Tiefe, und im ganzen File kein lat/lon. Liegt jetzt auf dem Gitter, mit den Schichtmitten als Tiefe und den echten HTESSEL-Grenzflaechen 0, 7, 28, 100, 289 cm als Bounds. Die aus den Mitten zu interpolieren waere bei so ungleichen Schichten Unsinn gewesen: die zweite Schicht ginge dann von 10,5 auf 40,75 cm statt von 7 auf 28.

## 6. `oplayer4` soll `pdepth` heissen

**erledigt** Und dahinter steckte mehr als ein Name. Die drei betroffenen Variablen `scint`, `phcint` und `absscint` lieferten ein Integral pro Wassersaeule, verlangt sind vier, eines je Schicht.

Welche vier Schichten das sind, steht in der Tabelle nicht: `oplayer4` ist `must_have_bounds: yes` mit leerem `bounds_requested`, geliefert werden nur die vier Werte 15, 50, 136 und 1000 bar. Das laesst sich aber ausrechnen. Euer Ozeanpapier zum Data Request nennt die Bereiche 0–300, 0–700, 0–2000 m und Rest. Mit  $p = \rho gh$ :

|                                     | 15    | 50    | 136    |
|-------------------------------------|-------|-------|--------|
| disjunkt (0–300, 300–700, 700–2000) | 15,08 | 50,28 | 135,75 |
| kumulativ (0–300, 0–700, 0–2000)    | 15,08 | 35,19 | 100,55 |

Also disjunkte Schichten, drei unabhaengige Treffer auf unter 0,3 bar. Der vierte Wert 1000 gehoert zu einer nach unten offenen Schicht unter 2000 m. Integriert wird ueber Tiefe, nicht ueber Druck, weil die Schichten in der Quelle Tiefenbereiche sind und auf der Achse nur als Druck ausgedrueckt werden. Modellschichten, die eine Grenze kreuzen, werden anteilig geteilt; die Summe der vier ergibt exakt das Saeulenintegral.

## 7. `lat(lat)` und `lon(lon)` auf regulaeren Gittern

**erledigt** Das war der groesste Einzelhebel: 41 Dateien ueber acht Checks, dazu der Grossteil der AICC006-Befunde zur Dimensionsreihenfolge.

Die Ursache lag eine Ebene tiefer als der Name. Der DReq benennt eine Dimension nach der angeforderten Stufe, auf die Platte gehoert der `out_name`, und 110 der Eintraege in `CMIP7_coordinate.json` unterscheiden sich darin. Wir hatten zwei Sonderfaelle fest verdrahtet, genau die zwei, die uns aufgefallen waren. Jetzt wird allgemein aufgeloeset.

Darunter lag noch ein zweiter Fehler derselben Sorte: die Liste, die Quelldimensionen auf DReq-Dimensionen abbildet, war ebenfalls handgepflegt und kannte `plev19`, aber nicht `plev7h`, und `olevel`, aber nicht `sdepth`. Eine nicht zugeordnete Dimension wird nicht umbenannt, sie landet unter ihrem Modellnamen in der Datei. Deshalb stand bei uns `pressure_levels_7h` und `sdepth` auf der Platte, und keine `out_name`-Aufloesung haette daran etwas geaendert. Beides kommt jetzt aus der Tabelle.

## 8. positive auf siflcondtop

**erledigt** Verstanden und umgesetzt: in den Variablentabellen ist **positive** eine Anweisung an den Produzenten, keine Metadatenangabe, und gehoert nicht in die Datei.

Das Vorzeichen selbst haben wir vorher geprueft, bevor wir das Attribut entfernt haben. **siflcondtop** rechnen wir aus **ist**, **sss** und **h\_ice**, und die Formel  $k(T_{\text{surface}} - T_{\text{base}})/h$  ist bereits die CMIP-Richtung: im Winter leitet Waerme nach oben aus dem Eis, also negativ. Gemessen 86,4 % negativ bei einem Mittel von  $-24,5 \text{ W m}^{-2}$ . Die Daten stimmten also, nur das Attribut musste weg.

## 4 Was dein Plugin darueber hinaus gefunden hat

| Fund                                          | Dateien | Stand                      |
|-----------------------------------------------|---------|----------------------------|
| coordinates listet Koordinatenvariablen       | 490     | <b>erledigt</b>            |
| Zeitachse hinter der horizontalen (msftbarot) | 1       | <b>erledigt</b>            |
| nz im coordinates von tob/sob                 | 2       | <b>erledigt</b>            |
| tclm ohne climatology_bnds                    | 1       | <b>erledigt</b> , s. u.    |
| olevel: lev fehlt ganz                        | 6       | <b>offen</b> , Modellseite |
| zonale Schnitte ohne eigenes Gitter           | 4       | <b>offen</b>               |

### pfull ist jetzt eine echte Klimatologie

Du hattest recht, dass da eine fehlte. **tclm** heisst laut CV zwoelf Werte, gemittelt ueber eine Anzahl Jahre, mit **time: mean within years** **time: mean over years**. Wir schrieben die zwoelf Monatsmittel eines einzigen Jahres darunter.

Alles neu zu rechnen scheidet bei uns aus: die Quelle ist 27 GB pro Jahr bei 194 Jahren, ein Neuaufbau waere rund 5 TB Lesen und wuerde mit jedem Lauf wachsen. Wir fuehren deshalb einen Zwischenstand ausserhalb des Laufverzeichnis, Summe und Anzahl der Jahre je Monat. Jeder Lauf addiert nur sein eigenes Jahr, die Klimatologie ist der Quotient und waechst mit. Welche Jahre schon eingerechnet sind, steht mit dabei, damit ein wiederholt cmorisiertes Jahr nicht doppelt zaehlt.

Das ist bei uns die einzige Datei, die nicht jahrweise archiviert werden kann. Alle anderen 539 sind es.

### Sechs Ozeanvariablen, bei denen die Daten fehlen

**osalttend**, **osaltrmadvect**, **osaltdiff**, **opottemptend**, **opottemprmadvect** und **opottempdiff** sollen (**time**, **lev**, **ncells**) sein und sind bei uns (**time**, **nod2**).

Das ist kein Metadatenproblem. Die Felder sind im FESOM-Diagnosemodul konstruktiv zweidimensional, der Quellcode sagt es selbst:

```
real(kind=WP), save, allocatable :: osalttend(:) ! Salinity tendency - 2D column-integrated
```

Ein XIOS-Eintrag auf ein 3D-Gitter laeuft ins Leere, wenn das Feld nur eine Dimension hat. Die sechs Regeln sind fuer HR deaktiviert. Der Term pro Level wird im Modell ohnehin gerechnet und nur aufsummiert, die Aenderung ist also klein; sie geht in die naechste Modellversion, und die betroffenen Variablen kommen mit dem LR-Lauf.

## 5 Offene Fragen an dich

### `grid_label` fuer Dateien ohne horizontales Gitter

Bei uns sind das 30 Dateien, alle mit `-hm-` in der Branding, also globale Mittel. Sie tragen aktuell noch `g130`, `g129` oder `g122` und behaupten damit ein Gitter, auf dem sie nicht liegen.

Wir haben im Register `g190` gefunden, "A single grid cell for the entire globe", und uns bewusst dagegen entschieden. Es ist ein echter Zelleneintrag mit Geometrie (`n_cells: 1`, `southernmost_latitude: -90`, `x_resolution: 360`, `y_resolution: 180`), wir wuerden also eine Ausdehnung behaupten, die unsere Dateien gar nicht mitliefern; sie enthalten weder `lat` noch `lon` noch Bounds. Ausserdem verweist im ganzen Register niemand darauf, und von 139 Eintraegen ist es der einzige mit einer Zelle. Es sieht also nicht nach einer etablierten Konvention aus, der wir uns anschliessen koennten.

Wenn der reservierte Bereich der ersten 100 Label dafuer vorgesehen ist, warten wir darauf.

### Sieben Achsen verlangen Bounds und liefern keine

`oplayer4` ist kein Einzelfall. In `CMIP7_coordinate.json` stehen sieben Eintraege auf `must_have_bounds: yes`, haben eine explizite Werteliste und kein `bounds_requested`:

```
alt16, alt40, dbze, oplayer4, plev7c, scattratio, tau
```

Bei `oplayer4` liessen sich die Schichten aus eurem Papier rekonstruieren, wie oben gezeigt. Fuer die uebrigen duerfte es anderen genauso gehen wie uns.

### Ein `requested`-Wert, den CF nicht kennt

`vegtype` setzt `standard_name = area_type`, und der CF-Standardname `area_type` schreibt vor, dass die Werte aus der CF-Area-Type-Tabelle stammen. In der `requested`-Liste steht aber `needleleaf_evergreen_tree` im Singular, den es dort nicht gibt; die anderen drei Baumtypen sind Plural, und die CF-Tabelle fuehrt durchgehend `needleleaf_evergreen_trees`. Von 247 geprueften CF-Begriffen ist das der einzige Ausreisser.

Wir schreiben den CF-Plural, weil derselbe Tabelleneintrag den Standardnamen setzt, der das verlangt. Dein Plugin meldet das folgerichtig als fehlenden Wert.

### Kleinigkeit

`time4` hat im `long_name` einen Tippfehler: "Monthly Mean Daily Satististics".

## 6 Was als naechstes kommt

`cli115` laeuft mit allem aus diesem Dokument. Die Gegenprobe schicken wir nach, sobald er durch ist.

Offen bleiben von unserer Seite die vier zonalen Schnitte (`msftm`, `hfbasin`, `sltbasin`), fuer die es kein passendes Gitter im Register gibt. Die Registrierung ist angestossen. Beim Nachmessen ist uns dabei aufgefallen, dass unsere drei zonalen Achsen nicht einheitlich sind, einmal 181 Punkte auf ganzen Grad und zweimal auf halben; das ziehen wir vorher gerade, damit die Registrierung nicht die Uneinheitlichkeit festschreibt.