

AWI-ESM3-4-2-veg-HR, CMIP7 piControl

Stand nach cli117, und was dein #67 sichtbar gemacht hat

Jan Streffing, AWI

8. September 2026

1 Kurzfassung

Es ist ein paar Wochen still gewesen, deshalb der Reihe nach. Seit der dritten Antwort gab es einen vollen Lauf, cli117, und seit vorgestern einen Checker-Stand, der die Zahlen deutlich verschiebt. Beides steht unten, dazu ein Befund bei uns, den wir nicht mehr reparieren koennen.

	cli117, alter Checker	heute, develop 8f2574c
Dateien	534	534
HIGH	24	65
MEDIUM	306	305

Der Sprung von 24 auf 65 kommt fast vollstaendig aus einer einzigen Pruefung, und die Dateien sind dabei in Ordnung. Das ist der erste Abschnitt.

2 TIME001 nach deinem #67

Wir haben den Checker-Checkout am 8. September von 88c6c45 (21. Juli) auf 8f2574c nachgezogen. Dabei kamen zehn Commits und drei PRs mit, #67, #74 und #76. Gemessen an denselben 534 Dateien kostet das 42 neue HIGH, alle aus TIME001:

Frequenz	Dateien	erwartet	gefunden	Abstand
1hr	19	365,041667	365,020833	30 min
3hr	12	365,125000	365,062500	1,5 h
dec	9	3652,5	1826,0	5 Jahre
6hr	2	365,250000	365,125000	3 h

Jeder Abstand ist genau eine halbe Zelle. Ein Beispiel, rsus stuendlich:

```
bnds[0] = [365.000000, 365.041667]    00:00 bis 01:00
time[0] = 365.020833    00:30, die Zellmitte
cell_methods = "area: time: mean"
Dateiname beginnt mit 185101010030
```

Der Dateiname traegt die erste Zeitkoordinate, so wie die CMIP7-Guidance es verlangt und wie du es in #58 selbst begruendet hast. TIME001 liest denselben Wert aber als Periodenanfang und addiert eine halbe Zelle, kommt also auf 01:00. Bei dec faellt es am staerksten auf, weil eine halbe Zelle dort fuef Jahre sind.

Das beruehrt auch #51 von uns aus dem Juni. Dort kamen 1hr, 3hr und 6hr in die AVERAGE_CORRECTION_FREQ, damit mittig gestempelte avg-Dateien bestehen. #67 hat die Liste wiederhergestellt, aber mit einem erwarteten Wert, der aus einem Token rekonstruiert wird, das bereits die Mitte ist.

Wir haben das als `cc-plugin-wcrp#80` aufgeschrieben, mit dem Reproduzierer. Von unserer Seite ist daran nichts zu machen: die Dateien stimmen, und den Stempel von der Zellmitte wegzuschieben wuerde die Daten falsch machen.

3 `plev7h`: das koennen wir nicht mehr reparieren

Der unangenehmste Punkt. Die fuenf 6-stuendlichen `plev7h`-Variablen (`hus`, `ta`, `ua`, `va`, `zg`) stehen auf den falschen Druckflaechen, und zwar seit dem Anfang des Laufs.

geschrieben	100000, 92500, 85000, 70000, 50000, 25000, 10000
verlangt	92500, 85000, 70000, 60000 , 50000, 25000, 5000

Fuenf Flaechen stimmen. 100000 steht, wo 60000 gehoert, und 10000, wo 5000 gehoert. Ursache ist eine Zeile in unserer XIOS-Konfiguration, die den CMIP6-Satz statt des CMIP7-Satzes anlegt.

Nachtraeglich ist nichts zu holen. Der Lauf hat 196 Jahre geschrieben, 1850 bis 2045, und endete am 27. August. Einen 6-stuendlichen Modellflaechen-Strom gibt es nicht, nur taeglich `c1` und `pfull` und monatlich `ta/hus/hur/cli/clw`. 60000 laege zwischen zwei vorhandenen Flaechen und waere interpolierbar, 5000 laege ueber der obersten und waere Extrapolation. Beides hiesse, eine Zahl unter einem Label auszuliefern, das Modellausgabe behauptet, und das wollen wir nicht.

Wir haben die fuenf Regeln deshalb deaktiviert und die Ursache dokumentiert, so wie vorher schon bei den sechs FESOM-Tendenzvariablen und den `mrso1`-Varianten. Die XIOS-Achse ist fuer den LR-Lauf korrigiert. Falls dir dazu etwas anderes einfaellt als weglassen, hoeren wir das gern.

Es kostet etwas. Die fuenf korrekten Flaechen sind 925, 850, 700, 500 und 250 hPa, 6-stuendlich ueber 196 Jahre, also genau das, was fuer Sturmzugbahnen gebraucht wird.

4 Zwei Fehler, die wirklich unsere waren

Beide kamen ans Licht, weil ich deine Befunde nach Zustaendigkeit sortiert habe und zwei davon in der falschen Schublade lagen.

slthick lag auf dem falschen Gitter. Die Regel las `atm_remapped_1m_1sm`, also die auf 640×1296 regriddete Land-See-Maske, deklarierte aber `g122`, das reduzierte Gauss-Gitter mit 421120 Zellen. Von allen unseren Regeln mit einer `atm_remapped_*`-Eingabe war sie die einzige mit `g122`, alle anderen tragen `g129`. Richtig ist trotzdem `g122`: `slthick` liefert die Schichtdicken zu `mrso1` und `ts1`, und wer die zusammen rechnet, braucht sie auf demselben Gitter. Die Regel liest jetzt ein natives Feld.

Darunter lag ein zweiter Fehler, der den ersten verdeckt hat. Unser Schritt broadcastete die vier Schichtdicken nur ueber die *letzte* horizontale Dimension. Auf einem unstrukturierten Gitter gibt es nur eine, dort ist das nie aufgefallen. Auf dem regulaeren wurde daraus `lon`, und die Breitenachse verschwand kommentarlos. `cli116` hat `slthick(depth, lon)` ausgeliefert.

depth trug weiter `units = "meter"` bei `ts1`, `mrso1` und `mrsl1`. Der Grund ist derselbe Namensbruch wie damals bei `plev`: unser Pass sucht die Achsen unter ihrem Namen aus der Datenanfrage, die Datei fuehrt sie unter dem `out_name`. Fuer `lev`, `plev` und `height` sind die gleich, fuer `sdepth` nicht, das steht als `depth` auf der Platte.

Eine Falle dabei, die der naheliegende Fix gestellt haette: `mrso1` gibt es zweimal, die Schichtvariante mit `meter` und die `d10cm`-Variante mit `cm`. Euer Checker erlaubt beide. Die CV-Einheit einfach durchzuschreiben haette Zentimeter zu Metern erkluert und die Schicht um Faktor 100 verschoben. Wir gleichen jetzt nur noch die Schreibweise an, nie die Einheit selbst.

5 Ein dritter Fehler, den erst #67 sichtbar gemacht hat

Als `dec` in die `AVERAGE_CORRECTION_FREQ` kam, lief `TIME001` zum ersten Mal auf unseren dekadischen Dateien. Dabei fiel etwas anderes auf: alle neun trugen Zeitgrenzen ueber ein Jahr statt ueber zehn.

Unser Code fuehrte `dec` zusammen mit `yr` und `yrPt`, also ging jede Datei mit genau einem Zeitpunkt durch den Jahres-Zweig. Nachgemessen an einem synthetischen Lauf war auch eine volle Dekade betroffen, es lag also nicht an unserem Einjahres-Testlauf. Behoben, `dec` bekommt jetzt einen eigenen Pfad und schnappt auf die Kalenderdekade.

Das raeumt den `TIME001`-Befund nicht ab, der haengt an #80. Aber ein Zehnjahresmittel sollte keine zwoelf Monate als Zellgrenzen fuehren, egal wer sie liest.

6 Nebenbei: unsere Koordinatentabelle war zwoelf Tage alt

Beim Aufräumen ist mir aufgefallen, dass wir gegen `CMIP7_coordinate.json` vom 2026-07-09 cmorisiert haben, waehrend `aicc` und `wcrp_cmip7` gegen den Stand vom 2026-07-21 validieren. Sieben Achsen weichen ab. Zwei davon sind sichtbar geworden:

- `typetreebd/be/nd/ne` trugen alle vier `value = "trees"`. Das ist genau dein Befund aus der Runde zu `cli112`. Ich hatte das im Code ueberschrieben, weil ich annahm, die Tabelle sei eben so. Upstream hatte die spezifischen CF-Flaechentypen laengst nachgezogen, mein Workaround war eine Kruecke fuer eine veraltete Datei.
- `deltasigt` hatte einen ganzen Absatz Prosa als `long_name`, inklusive literalem `\n\n`. In jeder `m1otst`-Datei stand deshalb ein `long_name` mit doppeltem Leerzeichen und ein `comment` mit dem Rest.

Die Tabelle ist jetzt auf dem Stand, gegen den auch geprueft wird, und ein Test schlaegt an, wenn ein kuenftiger Refresh wieder eine aeltere einzieht.

7 Das Zonalgitter, und ein Zeitfenster von drei Stunden

Die vier Dateien ohne eigenes Gitter (`msftm` auf Tiefe und auf Dichte, `hfbasin`, `sltbasin`) haben ihr Label bekommen. Registriert als `g239`, gemergt am 18.08. Die Achsen passten schon vorher: 180 Baender von $-89,5$ bis $89,5$ mit Schritt 1. Es fehlte nur das Label, vorher stand dort `g130` und behauptete damit die 3146761 FESOM-Knoten.

Das hat 15 der 27 verschwundenen HIGH gebracht. Und alle 16 neuen, denn `g239` kennt kein Checker:

4	[ATTR004] <code>grid_label</code> Vokabularpruefung
4	[FILE001] DRS-Verzeichnis
4	[FILE001] DRS-Dateiname
4	[AICC002] <code>grid_label='g239'</code> is not registered

Ich bin der Kette nachgegangen, weil mich interessiert hat, ob wir etwas falsch gemacht haben:

Stufe	g239	Zeitpunkt
EMD src-data	da	18.08., PR #1294
EMD production	da	18.08. 08:22
CMIP7-CVs <code>grid_label</code>	fehlt	letzter Sync 18.08. 05:34
esgvoc <code>cmip7@1.2.18</code>	fehlt	veroeffentlicht 19.08.

Der Sync von EMD in die CV laeuft als automatischer PR (`.github/scripts/sync_emd_entries.py`). Der letzte gemergte war #576 am 18.08. um 05:34. `g239` kam um 08:22 auf `production`, also zwei

Stunden und achtundvierzig Minuten zu spaet fuer genau diesen Lauf. g238 hatte es rechtzeitig geschafft und ist drin.

Stand 8. September. CMIP7-CVs#592 ist am 4. September gemergt, nachdem das CV-Komitee die Grundsatzfrage zu den „special grids“ geklaert hatte. Der Merge ist aber auf `esgvoc_dev` gelandet, nicht auf `main`: `grid_label/g239.json` liefert dort 404 und auf `esgvoc_dev` 200. Die neuesten CV-Releases sind 2.0.1 vom 1. September und 1.2.19 vom 26. August, beide aelter als der Merge. Es fehlt also nur noch der Schritt von `esgvoc_dev` nach `main` und ein Release danach.

Wir drehen g239 nicht zurueck: lieber 16 Befunde aus einem Terminproblem als vier Dateien, die ein Gitter behaupten, auf dem sie nicht liegen.

Falls du an der Stelle mehr Einblick hast als ich: aus Sicht eines Datenproduzenten ist das unangenehm, weil zwischen "Gitter ist registriert" und "Gitter validiert" ein Fenster von Tagen liegt, in dem ein Produktionslauf HIGH-Befunde einsammelt, die niemand beheben kann.

8 Was uebrig bleibt

65 HIGH, gemessen mit dem Checker-Stand von heute. 42 davon sind neu und kommen aus TIME001, die restlichen 23 kennst du aus der dritten Antwort:

42	TIME001, die halbe Zelle, <code>cc-plugin-wcrp#80</code>
16	g239, wartet auf ein CV-Release
5	plev7h, inzwischen deaktiviert, faellt im naechsten Lauf weg
1	vegtype, der Tabellenwiderspruch
1	pfull, die Klimatologie war in diesem Lauf schon aktuell

basin ist weg. Dein #67 hat den Befund „No geophysical variable detected“ behoben, nachgemessen an derselben Datei: 1 HIGH vorher, 0 nachher.

Zu `vegtype` noch ein Nachtrag, weil ich es diesmal nachgesehen habe: der geforderte Term ist `needleleaf_evergreen_tree`, im Singular, waehrend seine drei Geschwister im Plural stehen und wir `needleleaf_evergreen_trees` schreiben. Der Singular steht *in beiden* Koordinatentabellen, auch in der offiziellen vom 2026-07-21. Es ist also kein Versaeumnis von uns und auch keine Altlast unserer Kopie.

Der eine MEDIUM mehr ist ein CF-2.4-Befund auf `slthick`, und den handelt man sich genau dadurch ein, dass die Datei jetzt eine echte horizontale Dimension hat. Gleiche Klasse wie die anderen 75.

Zu den rund 70 `ATTR004-long_name-MEDIUM` haben wir am 25. August auf `WCRP-universe#190` eine Antwort bekommen. Die Korrektur laeuft ueber `known_branded_variables` auf der CV-Seite, geplant fuer September, und ausdruecklich: „since long_name values are not standardized, the reported issue remains a Medium severity warning and should not prevent you from publishing your data to ESGF“. Damit ist der groesste MEDIUM-Block eingeordnet.

9 Die fuenf fehlenden Sidecars aus c1i116

Beim Nachzaehlen von `c1i116` lagen nur 529 Reports auf 534 Dateien. Fuenf Dateien hatten gar keinen Sidecar. Die Ursache lag nicht an den Dateien.

Die fuenf sind vollstaendig und lassen sich einwandfrei pruefen, ich habe genau denselben Aufruf spaeter von Hand wiederholt und vier davon kamen ohne einen einzigen Befund zurueck.

Es lag an `cchecker.py` selbst. Er stirbt sporadisch schon beim Import, bevor er ueberhaupt eine Datei anfasst:

```
FileNotFoundError: [Errno 2] No such file or directory
File ".../bin/cchecker.py", line 10, in <module>
from compliance_checker.cf.util import download_cf_standard_name_table
File ".../compliance_checker/cf/util.py", line 17, in <module>
```

Unser Verdacht: parallele Shards, die gleichzeitig den Cache der CF-Standardnamentabelle anlegen wollen, und einer sieht die Datei halb geschrieben. Dazu passt, dass es in demselben Lauf und derselben Umgebung 529 mal geklappt hat und funf mal nicht, und dass der Wiederholungsversuch von Hand jedes Mal durchlief. Reproduzierbar ist es fuer mich nicht, deshalb bleibt es ein Verdacht. Falls du das kennst, wuerde mich interessieren woran es bei euch lag.

10 Warum das lautlos war, und was jetzt dagegen laeuft

Das ist derselbe lautlose Ausfall, den ich in der dritten Antwort im Zusammenhang mit `CMIP7_TABLES_PATH` beschrieben habe, nur mit einer anderen Ursache: der QC-Schritt hat protokolliert, dass kein JSON entstand, und ist weitergelaufen. Eine Datei ohne Sidecar wird danach nirgends mehr gezaehlt. Der Lauf sieht dadurch sauberer aus als er ist, und das ist die unangenehme Richtung des Fehlers.

Der QC-Schritt wiederholt den Aufruf jetzt bis zu dreimal, mit gestaffelter Pause, damit zwei kollidierte Shards nicht gleich wieder kollidieren. Wiederholt wird nur, wenn ueberhaupt kein Report auf der Platte liegt. Ein Report mit Befunden und Exitcode $\neq 0$ ist der Normalfall und wird wie bisher durchgereicht. Bleibt es auch nach dem letzten Versuch dabei, sagt die Fehlermeldung jetzt ausdruecklich, dass diese Regel ohne Report dasteht.

11 Was das fuer den Bestand heisst

Fuer `cli116` sind es jetzt 534 Reports auf 534 Dateien, und `cli117` hat von sich aus 534 auf 534 geliefert. Der Wiederholungsversuch hat dort nicht einmal ausgeloeset, es gab schlicht keinen Importfehler. Die Zahl ist also echt und nicht gerettet. Die fruerehen Laeufer haben wir nicht nachgezaehlt. Falls dir in Zahlen aus `cli108` bis `cli115` etwas nicht aufgeht, koennte das derselbe Effekt sein, und ich schaue gezielt nach.