

AWI-ESM3-4-2-veg-HR, CMIP7 piControl

Stand nach cli118: deine aicc-0.2-Befunde zu cli117

Jan Streffing, AWI

11. September 2026

1 Kurzfassung

Danke fuer den Lauf mit `cc-plugin-aicc 0.2` auf `cli117`. Alle Befunde, die bei uns lagen, sind behoben und in `cli118` nachgemessen, dem Jahr 1851 mit 529 Dateien. Fuenf davon haben wir nach zwei Nachkorrekturen noch einmal geschrieben, dazu Abschnitt 11.

Befund aus deinem Lauf	cli117	cli118
lon unter <code>valid_min</code> = 0	299	0
<code>time2/time4</code> ohne <code>climatology</code>	3	0
<code>g132</code> : zwei Saetze Koordinaten	2 Variablen	0
<code>hur: missing_value/_FillValue</code> unterschiedlich getypt	3	0
Daten als <code>double</code> , obwohl der Data Request <code>real</code> verlangt	227	0
<code>long_name</code> <code>Latitude/Longitude</code>	41	0
<code>long_name</code> <code>ap(k+1/2)/b(k+1/2)</code>	9	0
<code>g239</code> im Vokabular und DRS	12	0
<code>plev7h</code>	5	deaktiviert
<code>TIME001</code>	42	42

In `cli118` bleiben damit 43 HIGH ueber alle drei Checker: `cf` 0, `wcrp_cmip7` 42, `aicc` 1. Die 42 sind `TIME001` und haengen an deinem `#81`, der eine `aicc`-Befund ist `vegtype`. Beides kommt in Abschnitt 9.

2 Laenge in $[0, 360]$

Die Tabelle verlangt fuer `longitude` und fuer `vertices_longitude` in `CMIP7_grids.json` `valid_min` = 0 und `valid_max` = 360. In `cli117` lagen 299 Dateien in $[-180, 180]$, betroffen waren `g122` auf `ncells` sowie alle Dateien auf `g130` und `g132`. Daneben lagen 161 `g122`-Dateien schon im anderen Bereich. Dasselbe Gitterlabel kam also mit zwei Koordinatensaetzen, und das duerfte ein guter Teil der Konsistenzbefunde zwischen den Datasets gewesen sein.

Hilfskoordinaten und Eckpunkte werden jetzt in den Bereich gebracht. Dimensionskoordinaten bleiben unberuehrt, dort wuerde das Umklappen die Monotonie zerstoeren, und `g129` lag ohnehin schon in $[0, 360]$. Zellen, die ueber den Nullmeridian reichen, haben ihre Eckpunkte danach an beiden Enden des Bereichs, so wie CMOR sie schreibt. Der `cf`-Test, ob die Koordinate in ihrer Zelle liegt, rechnet die Laenge dafuer zurueck, das haben wir auch in eurem `compliance-checker`-Checkout nachgesehen.

3 `g132`: ein Satz Koordinaten

Dein Hinweis, dass `tauuo/tauvo` ein anderes Minimum haben als `hfx/hfy`, lag an zwei Quellen. `tauuo` und `tauvo` kommen mit den Elementschwerpunkten aus XIOS, `hfx` und `hfy` bekamen unsere, als Mittel der drei Eckknoten auf der Kugel. Unser Schritt hat die XIOS-Werte bisher stehen lassen, sobald eine Datei ueberhaupt `lat` mitbrachte.

Die beiden Saetze wichen auf 3,96 Mio. Zellen voneinander ab, auf 1272 polnahen Zellen um bis zu 57,6 Grad in der Laenge. XIOS mittelt dort die Eckpunkt-Laengen in Grad, und das geht in Polnaehe schief. Auf dem Elementgitter ersetzen wir jetzt immer. Alle neun `g132`-Dateien in `cli118` haben bitgleiche `lat`, `lon` und Eckpunkte.

4 Datentyp nach dem Data Request

Alle Gleitkommavariablen im CMIP7 Data Request sind `real`, also einfach genau. 227 der 534 Dateien in `cli117` waren `double`, meist weil eine Einheitenumrechnung oder eine Mittelung `float32`-Eingaben hochgestuft hatte. Die Daten werden jetzt vor dem Schreiben auf `float32` gebracht, und `missing_value` und `_FillValue` folgen dem Typ der Daten.

Bei `hur` lag noch eine zweite Ursache darunter. Die Feuchteachsen `hur100p2pct` und `hur101pct` haben in der Koordinatentabelle den `out_name` `hur`, und unser Schritt, der Koordinaten auf den Tabellentyp bringt, hat deshalb die Variable selbst wieder als `double` geschrieben, mit `float32`-Fuellwerten. Das war genau die Typmischung, die der cf-Checker gemeldet hat und an der `check_appendix_a` abgestuerzt ist. Der Schritt fasst jetzt nur noch Koordinaten an. In `cli118` ist keine Variable mehr `double`, und der Absturz ist weg.

5 `time2` und `time4` als Klimatologie

`pfull tclm` und `tas tmaxavg/tminavg` tragen jetzt `time:climatology = "climatology_bnds"` und kein `bounds` mehr. Fuer `time4` spannt `climatology_bnds` den jeweiligen Monat. Fuer `time2` laufen die Grenzen vom Monatsanfang im ersten bis zum Monatsende im letzten Jahr, das in den Akkumulator eingegangen ist. Den Mittelungszeitraum aus `DReq#32` legen wir damit so aus: alle emorisierten Jahre des Laufs. Im Testjahr fallen beide Formen zusammen.

Eine Kleinigkeit dabei: `climatology_bnds` steht numerisch in den Einheiten der Zeitachse auf der Platte, ohne eigene Attribute. `xarray` raemt `units` und `calendar` nur von der Variable ab, auf die `bounds` zeigt, nicht von der unter `climatology`. Sonst haette cf Appendix A `calendar` auf einer Datenvariable gemeldet.

Den Tippfehler `Satistics` im `long_name` von `time4` uebernehmen wir aus der Tabelle, der steht schon in deinem `CMIP7_DReq_Content#31`.

6 `long_name` nach Tabelle

Dimensionskoordinaten tragen jetzt `Latitude/Longitude` wie in `CMIP7_coordinate.json`. Die Hilfskoordinaten auf unstrukturierten Gittern bleiben kleingeschrieben, dort gilt `CMIP7_grids.json`. Die Formelterme der Grenzen heissen $a_p(k+1/2)$ und $b(k+1/2)$.

7 Gitterregister in `aicc`

`aicc` fuehrt ein festes Register von `g100` bis `g236`. Seitdem sind 17 Labels ins CV gekommen, die Spezialgitter `g010` bis `g014` und `g237` bis `g248`, darunter unser `g239` und das LR-Gitter `g238`. Wir uebergeben deshalb ein eigenes Register per `-0 aicc:grid_config:<json>`: euer Register plus

15 Labels, der Typ jeweils aus dem `grid_type`, den EMD fuer das Label fuehrt. `g013` und `g014` fehlen darin, fuer Punkte und Linien kennt `aicc` keine Topologie. Die 137 vorhandenen Eintraege stimmen alle mit EMD ueberein.

Falls dir das recht ist, schreiben wir das als Issue bei `cc-plugin-aicc` auf. Ein Register, das aus dem CV gelesen wird, wuerde es gar nicht erst veralten lassen.

Mit dem Register wurde auch etwas sichtbar, das vorher an der Gitterpruefung haengen blieb: `msftm` stand als `(time, lev, basin, lat)` auf der Platte, die Tabelle verlangt `(time, basin, lev, lat)`. Behoben, die Hauptvariable folgt jetzt der Dimensionsfolge des Data Request, sobald alle ihre Dimensionen darauf abbilden.

8 Globale Mittel auf `g010`

Die 29 Variablen mit horizontalem Mittel lagen bisher auf `g190`. Nach der Klaerung im CV-Komitee ist `g190` ein Box-Modell-Gitter ([Essential-Model-Documentation#1382](#)), und fuer globale Mittel gilt das Spezialgitter `g010`. Umgestellt. Die Variable Registry-Befunde auf `so` und `thetao` aus deinem Lauf tauchen bei uns nicht auf, beide Terme stehen in `branded_variable/` von CMIP7-CVs. Wir vermuten dort einen aelteren CV-Stand auf deiner Seite.

9 Was uebrig bleibt

Anzahl	Befund	wartet auf
42 HIGH	TIME001, die halbe Zelle	<code>cc-plugin-wcrp#81</code>
1 HIGH	<code>vegtype</code> auf <code>landCoverFrac</code>	<code>CMIP7_DReq_Content#29</code>
492 MEDIUM	„Registry has no value for key 'cell_measures'“	<code>WCRP-universe#334</code>

TIME001. Laut Beschreibung von `#81` addiert TIME001 bei subdaily und dekadischen Daten keine halbe Zelle mehr und prueft den midpoint gegen die deklarierten Grenzen. Das sind genau unsere 42. Sobald `#81` gemerget ist, pruefen wir `cli118` damit.

Die 492 MEDIUM. Die sind neu, seit wir auf `cmip7@2.3.0` gewechselt sind, und sie liegen nicht an den Dateien. Die Universe-Datenbank 3.2.0, die esgvc aus der Registry laedt, fuehrt fuer `known_branded_variable` kein `cell_measures` und `units` statt `cf_units`, obwohl das JSON im Repository beides noch hat. Ein Update von esgvc 4.1.1 auf 6.1.0 aendert daran nichts. Das ist `WCRP-universe#334` und `cc-plugin-wcrp#79`, und dein `#81` erwaehnt genau diese Kompatibilitaet (`units` vs. `cf_units`). Wir erwarten also, dass die 492 mit `#81` ebenfalls verschwinden.

Zwei Stellen, die wir im cf-Checker selbst sehen. Sie stehen nicht in der Tabelle, weil sie nicht an uns haengen:

- `formula_terms` auf `lev_bnds`, in deinem Lauf acht HIGH aus Appendix A. `cf_1.7.py` verlangt das Attribut auf den Grenzen einer parametrischen Vertikalkoordinate, wie CF 1.7 §7.1 es vorschreibt, der Appendix-A-Test verbietet es dort. Eine Datei kann nicht beides erfuehlen, wir behalten es daher.
- Der Test fuer `cell_methods` von Klimatologien ist auf `time`: verankert. Seit `time2/time4` richtige Klimatologien sind, faellt deshalb `area: mean time: maximum within days time: mean over days` als MEDIUM durch, obwohl CF andere Achsen davor zulaesst. Drei Dateien.

Beides wuerden wir bei `compliance-checker` aufschreiben, ein bestehendes Issue dazu haben wir nicht gefunden.

10 Die FileNotFoundError

Das war nicht diese Woche. Gemeint sind die fuenf fehlenden Reports aus `cli116` vom 18. August, beschrieben in der vierten Antwort: `cchecker.py` ist dort beim Import gestorben, bevor er eine Datei angefasst hat. Seitdem wiederholt der QC-Schritt den Aufruf, wenn kein Report entsteht. `cli117` hat 534 Reports auf 534 Dateien geliefert, `cli118` 529 auf 529. In den 63 Logs von `cli118` steht kein einziger `FileNotFoundError`, und die Wiederholung hat nie ausgelöst.

Ob es die Lustre-Probleme waren, koennen wir nicht sagen, der Fehler war nicht reproduzierbar.

11 Wie gemessen wurde

`cli118` lief am 10./11. September mit allen Korrekturen ausser zweien: `hur` war noch `double` (die zweite Ursache oben) und `msftm` in der alten Dimensionsfolge. Beides ist behoben, und die fuenf betroffenen Dateien sind am 11. September in denselben Lauf neu geschrieben. Alle Zahlen oben beziehen sich auf diesen Stand.

Checker-Stand: `compliance-checker` 6.1.0, `cc-plugin-wcrp` develop ba2de16, `cc-plugin-aicc` 0.2.0 mit unserem Register, `esgvoc` 6.1.0 mit `cmip7@2.3.0` und `universe@3.2.0`. Die `plev7h`-Variablen sind wie angekündigt deaktiviert, daher 529 statt 534 Dateien.

Gute Erholung im Urlaub. Das hier liegt bereit, wenn du zurueck bist.