

AWI-ESM3-4-2-veg-HR, CMIP7 piControl

Antwort auf das DKRZ-Review von cli108
und Ergebnisse der anschließenden eigenen Nachsuche

Jan Streffing, AWI

9. August 2026

1 Kurzfassung

Du hast uns zu cli108 (Version v20260804) zwei Runden geschickt. Beide sind abgearbeitet und zusammen verifiziert. Der aktuelle Stand ist cli111, 540 Dateien:

	cli108	cli111
HIGH	1	1
MEDIUM	758	233
TIME001 / TIME003		0
Dateien mit falschem <code>grid_label</code>		0
Dateien, die netCDF-C nicht öffnen kann		0

Das verbleibende HIGH ist `basin` und stammt aus einer Regression in `cc-plugin-wcrp` (#66), nicht aus unseren Daten.

Neben den Review-Punkten haben wir eine eigene Suche nach Quelle-gegen-DReq-Fehlern gemacht. Anlass war `mrso1`: dort zeigte sich, dass ein einzelner Ausgabestrom mehrere DReq-Einträge gleichzeitig falsch bedienen kann und *kein* QC-Check das findet. Diese Suche hat sieben weitere Punkte gefunden, darunter zwei mit falschen Werten und einen, bei dem eine Datei gar nicht mehr lesbar war.

Umfang seit dem letzten Commit vor dem Review (b42279a2): 19 Commits, 23 Dateien, +2477 / -377 Zeilen.

2 Teil 1 deines Reviews: Antwort auf die Punkte

1hr, hfls: lon_bnds/lat_bnds fehlen, keine time-Variable

erledigt Das war kein Metadatenfehler. Der Shard lief in die SLURM-Walltime, und ein abgebrochener Schreibvorgang hinterlässt eine Header-only-Datei statt eines Fehlers. Der Tier `extra_atm` hat jetzt 6 h. cli111: 8760 Zeitschritte, `lat_bnds` und `lon_bnds` vorhanden.

Der Fehlermodus ist unangenehm, weil er lautlos ist. Wir haben deshalb auch `cap7_atm` vorsorglich auf 6 h gesetzt, nachdem dort der Input um Faktor 26 gewachsen ist (siehe `hurs` im Abschnitt zur eigenen Nachsuche).

1hr, hfls: `_QuantizeBitGroomNumberOfSignificantDigits`

erledigt Danke für den Hinweis auf CF 1.12. Umgesetzt wie in der Konvention: ein Container `quantization_info` mit `algorithm = "bitgroom"` und `implementation = "netCDF-C version`

4.9.3-development", dazu pro Variable `quantization = "quantization_info"` und `quantization_nsd = 5`. Das führende Unterstrich-Attribut wird jetzt entfernt, das verstieß ohnehin gegen CF §2.3.

1hr, rsus: Repacking-Checks

erledigt `cmip7repack` läuft bei uns als fester Teil des Schreib-Workflows auf jeder Datei, nicht erst vor der Publikation, in `cli111` 542-mal.

Alle drei gemeldeten Punkte sind damit weg:

Befund	gemeldet	cli111
time	18 Chunks	1
time_bnds	8760 Chunks	1
consolidated metadata	fehlte	165725 B in einem Block

Gegengeprüft auf genau der Datei, die du zitiert hattest. `cmip7repack -x` meldet "not rechunking" für `time`, `time_bnds` und `rsus`, es bleibt also nichts zu rechunken. Und `h5stat -S` zeigt `File metadata: 165725 bytes`, genau die `metadata_block_size`, die `cmip7repack` für diese Datei berechnet und gesetzt hat, die Metadaten liegen also in einem Block.

3hr, mrsol: erster Zeitschritt (01:30) fehlt

erledigt, aber die Ursache lag tiefer, und der Hinweis war deshalb sehr nützlich.

Ein einziger 3-stündiger XIOS-Stream (`operation="instant"`, Feld: oberster Meter) bediente drei DReq-Einträge, die sich sowohl in der Tiefe als auch in der temporal shape unterscheiden. Zwei Folgen:

- `tavg-d100cm` bekam instantane Samples und konnte damit kein Mittel sein. Das war der von dir gesehene fehlende erste Zeitschritt.
- Beide `d10cm`-Einträge lasen still das 100-cm-Feld, publizierten also 1 m Bodenfeuchte unter einem 10-cm-Label.

Der Tiefenfehler ist an `cli108` belegbar: 3hr `d10cm` hatte ein Mittel von $72,6 \text{ kg m}^{-2}$ gegen 6,9 bei der echten 10-cm-Monatsregel, Verhältnis 10,5 und damit genau das Tiefenverhältnis 1,00 m / 0,10 m. Das sind falsche Werte, kein Metadatenproblem, und kein QC-Check schlägt an.

Die drei Regeln sind vorerst deaktiviert. In `esm_tools` sind drei getrennte Streams ergänzt (100 cm gemittelt, 10 cm instantan, 10 cm täglich gemittelt), sodass künftige Läufe inklusive LR sie reaktivieren können.

Allgemein: fehlende scalar coordinates

erledigt Du hattest recht, die fehlten durchgängig. Wir lesen jetzt `CMIP7_coordinate.json` und schreiben beide Sorten:

- numerisch mit `value: height2m, height10m, sdepth10cm, ...`
- character: `typetree`, `typec3crop` und weitere Tile-/Area-Typen, `out_name` meist `type`

Beide werden in `coordinates` der Datenvariable referenziert. `cli111, sfcWind: coordinates = "time lat lon height"`.

Allgemein: globales Attribut `experiment`

erledigt Enthält jetzt die CV-Beschreibung, über `esgvoc` aufgelöst, statt noch einmal die `experiment_id`.

Allgemein: CF-Checker, coordinates als globales Attribut

erledigt Entfernt. Eine Warnung für andere Gruppen mit demselben Problem: der naheliegende Weg `ds.encoding["coordinates"] = None` auf Dataset-Ebene wirkt *nicht*. Wir haben das empirisch geprüft, `xarray` schreibt das Attribut trotzdem. Nur `reset_coords` auf den Bounds-Koordinaten hilft. Auf *Variablen*-Ebene funktioniert `encoding["coordinates"] = None` dagegen sehr wohl, was die Sache verwirrend macht.

Allgemein: TIME001 squareness bei `tavg`

erledigt In `cli111` null Treffer, ebenso TIME003. Der Rest kam aus den inzwischen gemergten Upstream-PRs plus unserer Korrektur des Dateinamen-Tokens auf `time[0]/time[-1]` nach CMIP7 Appendix 1.

3 Teil 2 deines Reviews: Antwort auf die Punkte

Alle vier Punkte sind umgesetzt und in `cli111` verifiziert.

string statt character bei Koordinatenvariablen

erledigt Und der Hinweis war wichtiger, als er aussah. Wir schreiben jetzt `char sector(<out_name>, strlen)`, geprüft gegen publizierte MPI-ESM1-2-LR-Dateien. `cSoilPools` war auf allen drei Punkten falsch und ist jetzt `char sector(type, strlen)`, `long_name = "Soil Pools"`, ohne `units`. Bei `landCoverFrac` heißt die Dimension jetzt `type` statt `vegtype`; dass der `out_name` zur Dimension wird, hatten wir zuerst anders entschieden, deine Beschreibung war eindeutig.

Der Grund, warum das mehr als eine Konvention ist: bevor wir es korrigiert hatten, lagen fünf Dateien vor, die `netCDF-C` gar *nicht* öffnen konnte.

```
cropFrac, shrubFrac, baresoilFrac, treeFrac, grassFrac (yr)
RuntimeError: NetCDF: HDF error
```

Deren skalare `type`-Koordinate ging als `NC_STRING` raus, und `h5py` meldet eine korrupte `creation property list` auf dem `vlen`-Dataset. Der Compliance-Checker meldet dieselben Regeln mit `high=0` `medium=0` `low=0`. Wir hatten das zunächst isoliert nachgestellt und dabei *keinen* Fehler gesehen; er tritt erst im vollständigen Schreibpfad auf. Als Hinweis für die QC: eine Datei, welche die Bibliothek nicht öffnen kann, sollte kein sauberes Ergebnis bekommen.

axis = X/Y auf unstrukturierten Gittern

erledigt Entfernt, und du hast die Begründung schon geliefert: `nod2` ist eine Indexdimension. Wir setzen `axis` jetzt nur noch auf echten Koordinatenvariablen, deren einzige Dimension ihr eigener Name ist. `CMIP7_grids.json` führt bei `latitude/longitude` ebenfalls kein `axis`. Betroffen waren 437 von 540 Dateien. Das `coordinates`-Attribut auf `lat_bnds/lon_bnds` (274 Dateien) ist ebenfalls weg.

olevel ist nur ein Platzhalter

erledigt Aufgelöst zu `depth_coord`, `out_name lev`. Damit kamen gleich drei Dinge in Ordnung: der Name, die von `must_have_bounds: yes` verlangten `lev_bnds`, und die Attribute. Letztere kamen bisher aus dem Modell (`units = "meter"`, ein Nicht-CF-Attribut `name = "nz"`); jetzt gewinnt das CV. Die fehlenden Bounds hatten eine eigene Ursache: der Bounds-Schritt läuft vor dem Umbenennen und kannte den FESOM-Namen `nz1` nicht.

alevel: parametrische Koordinate mit formula_terms

erledigt Gewählt ist `alternate_hybrid_sigma`, $p = ap + b \cdot ps$. Die Dateien enthalten jetzt `lev`, `lev_bnds`, `ap`, `b`, `ap_bnds`, `b_bnds`, `ps` und die `formula_terms`.

Die A/B-Koeffizienten stehen nicht im Modell-Output; sie kommen aus der ECMWF-Vertikaltabelle für L137, die zur Diskretisierung gehört und mit den Modell-Inputdaten ausgeliefert wird. `ps` muss Gitter *und* Zeitachse der Variablen teilen: das cmorisierte `ps` liegt auf dem regulären Regrid und scheidet damit aus, also lesen wir den nativen 6-stündlichen Strom und mitteln ihn über die Ausgabeintervalle.

Zwei Fehler dabei sind uns nur aufgefallen, weil wir Feld für Feld gegen eine publizierte MPI-ESM-Datei verglichen haben, nicht weil QC etwas gesagt hätte: `lev` bekam zwischenzeitlich die Ozean-Metadaten (`standard_name = depth`, `units = m`) auf 137 Modelllevel, und `ap/b` wurden mit BitGroom auf 5 signifikante Stellen quantisiert, also verlustbehaftet genau auf den Koeffizienten, aus denen die Vertikalachse rekonstruiert wird. Beides ist behoben, `ap` und `b` sind bitgenau gegen die Tabelle.

Nebenbefund aus deinem Hinweis auf `CMIP7_grids.json`: `grid_label`

Beim Nachsehen ist uns aufgefallen, dass 161 Regeln ein `grid_label` trugen, das ein anderes Gitter beschreibt, darunter 142 Dateien mit `g113`. Das ist ein reguläres 0,25-Grad-Gitter mit 1036800 Zellen und gehört nicht uns.

Ursache: `grid_label` stand einmal pro Tier im `inherit`-Block, und ein Tier, dessen Regeln nativen und regemappten Strom mischen, stempelte beiden dasselbe Label auf. Da `grid_label` in Pfad *und* Dateinamen steht, lässt sich das nachträglich nicht reparieren.

Eine Fufangel dabei, die für andere Gruppen mit ähnlichem Aufbau vielleicht nützlich ist: wir setzen `grid_label` pro Tier in einem `inherit`-Block und überschreiben es auf einzelnen Regeln. Diese Überschreibungen wurden still wieder auf den Tier-Wert zurückgesetzt, weil die Vererbung nach dem Zusammenbauen der Regeln noch einmal über alle lief und dabei trotz `force=False` zuwies. Sichtbar war das nur als Warnungen "Attribute `grid_label` already exists" im Log. Und weil zwei Regeln, die sich nur im Gitter unterscheiden, damit denselben DRS-Pfad bekommen, hat `areacella` seinen Zwilling überschrieben, also eine Datei weniger als erwartet.

In `cli111` stimmt bei allen 540 Dateien das `grid_label` mit der tatsächlichen Zellzahl überein, geprüft Datei für Datei.

Alle vier Gitter, die wir tatsächlich schreiben, waren bereits registriert:

Gitter	Zellen	Label
OIFS TCo319 reduziert gaußsch	421120	<code>g122</code>
OIFS Regrid 640×1296	829440	<code>g129</code>
FESOM DARS Knoten	3146761	<code>g130</code>
FESOM DARS Elemente	6229020	<code>g132</code>

Zwei weitere Zellmengen sind echte Teilmengen des TCo319-Gitters (LPJ-GUESS-Landpunkte 107132, Region 30S–90S 94572) und behalten `g122`. Beide hatten allerdings überhaupt keine Zellgrenzen, waren also gar nicht als TCo319-Zellen ausgedrückt; das ist jetzt korrigiert, 173 Dateien.

Offen ist nur, welches `grid_label` eine Datei tragen soll, die gar kein horizontales Gitter hat (globale Mittel, Becken-Schnitte, Profile; bei uns 36 Dateien). CMIP6 hatte `gm`, im numerischen Schema finden wir keine Entsprechung, und `g999` hat eine leere Beschreibung. Falls du weißt, was hier vorgesehen ist, wäre das die letzte offene Frage aus diesem Block.

4 Eigene Nachsuche (unabhängig von deinem Review)

Ein Stream, der mehrere DReq-Einträge bedient, kann diese gleichzeitig falsch bedienen, und QC sieht davon nichts. Wir haben deshalb systematisch die Quelle jeder Regel gegen ihren `compound_name` geprüft. Sieben Befunde, alle verifiziert:

1. **18 *Lut-Regeln ohne landuse-Achse.** Publiziert wurde nur die Spalte `ps1`. Die DReq-Dimensionen sind `longitude latitude landuse time`. Alle vier Kacheln standen in den Quelldateien, es war reine Loader-Arbeit. Jetzt 4 Werte in DReq-Reihenfolge.
2. **landCoverFrac ohne vegtype-Achse.** Die 44 PFT-Spalten wurden zu einem Skalar aufsummiert. Jetzt 7 Werte. Die Zuordnung stammt aus den Instruktionsdateien des Laufs selbst (`global.ins`, `arctic.ins`, `wetlandpfts.ins`, `crop_n.ins`, `landcover.ins`), nicht aus den PFT-Kürzeln. Nicht zuordenbare Spalten lösen jetzt einen Fehler aus, statt still wegzufallen. `CLM`, `pCLM`, `pmoss` und `Bare_soil` haben keine Entsprechung auf der `vegtype`-Achse und fehlen daher, was im `comment` der Variable steht.
3. **mrsolLut las die ganze Bodensäule** unter `d10cm`-Label. Die passende 0–10-cm-Ausgabe lag ungenutzt daneben. Umgestellt. Gleiche Fehlerklasse wie bei `mrsol`.
4. **sivol täglich: 12 Monatswerte auf 335 Tagesschritte**, davon 323 NaN. Die richtige Eingangsgröße `m_ice` liegt nur monatlich vor, `h_ice` und `a_ice` aber täglich, und $m_ice = h_ice \cdot a_ice$. Wir rekonstruieren das Tagesfeld daraus.
Die Näherung ist gemessen, nicht geschätzt: in einem Testlauf schreibt FESOM `sivoln` jeden Modellzeitschritt (87 600 Samples), das ist FESOMs eigene Eisvolumen-Diagnostik. Gegen die Rekonstruktion:

10^3 km^3	min	max	Mittel
FESOM <code>sivoln</code> , auf Tage gemittelt	10,911	29,497	20,585
Rekonstruktion $h_ice \cdot a_ice$	10,921	29,524	20,605

Abweichung im Mittel +0,094 %, maximal 0,107 %, Korrelation 1,000000. Der Rest ist die sub-tägliche Kovarianz zwischen Dicke und Konzentration, die das Produkt zweier Tagesmittel verliert. Gemessen: 365 Zeitschritte, keine NaN. Ein täglicher `m_ice`-Stream ist in `esm_tools` ergänzt und macht die Näherung für spätere Läufe überflüssig.

5. **sistressave und sistressmax: Monatsmittel als tpt gelabelt.** Beide DReq-Einträge wollen einen Momentanwert zur Monatsmitte, FESOM schreibt `sgm11/sgm12/sgm22` als Monatsmittel. Bei `sistressmax` ist es mehr als ein Labelproblem: die Invariante $\sqrt{((\sigma_{11} - \sigma_{22})/2)^2 + \sigma_{12}^2}$ ist nichtlinear in den Komponenten, aus Monatsmitteln berechnet ist sie nicht einmal das Monatsmittel der Invariante. Ausgabe pro Zeitschritt wäre der einzige Weg und ist bei HR mit grob 1,5 TB pro Jahr und Komponente nicht machbar. Beide Regeln deaktiviert, instantane Streams in `esm_tools` ergänzt.
6. **hurs Tagesmaximum und -minimum aus Tagesmitteln.** Es fehlte schlicht eine max/min-Reduktion. Die gibt es jetzt, gespeist aus Stundenwerten. Das ist eine Näherung gegenüber Extrema auf Modellzeitschritt-Ebene, aber konsistent mit dem, was viele CMIP7-Modelle liefern werden.
7. **emibb*: fFireAll oder fFireNat?** Die DReq gibt keine Beschreibung. Domänenentscheidung, bestätigt als `fFireAll` inklusive Landnutzungsfeuer. Das bisherige Verhalten war richtig, dokumentiert, damit die Frage nicht wieder aufkommt.

Nebenbefund: QC meldet eine unlesbare Datei als sauber

Beim Bau der `landuse`-Achse haben wir die Labels zunächst als Python-Strings abgelegt. `xarray` schreibt daraus eine `NC_STRING`-Variable, und die resultierende Datei ließ sich von `netCDF-C` überhaupt nicht mehr öffnen: `ncdump` und `netCDF4.Dataset` scheiterten beide mit `NetCDF: HDF error`, `h5py` meldete eine korrupte creation property list (`bad global heap collection signature`) auf dem `vlen-Dataset`.

Der Compliance-Checker meldete dieselbe Datei mit `high=0 medium=0 low=0`.

Wir schreiben die Achsen jetzt als `char sector(landuse, strlen)`, also so, wie CMOR es tut, geprüft gegen publizierte MPI-ESM1-2-LR-Dateien. Das behebt es vollständig. Der Hinweis könnte für die QC allgemein interessant sein: eine Datei, die die Bibliothek nicht öffnen kann, sollte kein sauberes Ergebnis bekommen.

5 Verbleibende Befunde in cli111

Anzahl	Check	Einordnung
1	basin HIGH	upstream , cc-plugin-wcrp #66
112	ATTR004 long_name	Registry-Erwartung, gemischt, s. u.
39	ATTR004 cell_measures	Registry will volume: volcello dazu
36	ATTR001 cell_measures	fehlt auf den fx-Flächenvariablen selbst und auf globalen Skalaren, die keins haben
26	CF §2.4	Dimensionsreihenfolge, mit den alevel-Dateien von 17 gestiegen
9	CF §7.1	lev_bnds:formula_terms, teilen publizierte CMOR-Dateien mit uns
1	CF §6.1	basin, Rest des upstream -Befunds

Eine Messungenauigkeit in eigener Sache: QC-Reports werden nach Regelnamen benannt, und sieben Regelnamen kommen in mehreren Tiers vor (evspsbl in dreien, dazu areacella, prsn, sbl_mon, snd_day, snw, ts). Acht der 540 Regeln überschreiben damit den Report einer anderen. Die Daten sind davon nicht betroffen, sie liegen wegen unterschiedlicher realm/compound_name in verschiedenen Pfaden; die Zahlen oben sind aber eine leichte Unterschätzung.

Wir haben die ATTR004-Gruppen einzeln gegen den Data Request gehalten:

Gruppe	Befunde	bei uns	Registry $\neq$ DReq
long_name	112	1	107 (+4 ohne DReq-Eintrag)
cell_measures	39	39	0
cell_methods	10	0	10

Bei long_name schreiben wir also in 107 Fällen genau den Wert, den der Data Request vorgibt, und die Registry erwartet einen anderen. Das Muster ist eindeutig, weil es die Branding-Variante ignoriert:

Variable	DReq und wir	Registry
cVeg_tavg-u-hxy-shb	... on Shrub Tiles	... on Grass Tiles
cVeg_tavg-u-hxy-u	Carbon Mass in Vegetation	... on Grass Tiles

Jede cVeg-Kachel bekommt denselben long_name. Dazu passt, dass cVeg_tavg-u-hxy-shb in WCRP-universe/known_ gar nicht existiert (HTTP 404), der Checker also auf einen anderen Eintrag derselben Variablenwurzel zurückfällt. Dasselbe bei cell_methods: für unser atmos.rlus.tavg-u-hxy-u wird die Sea-Ice-Variante "area: time: mean where sea_ice (mask=siconca)" erwartet, während der Eintrag rlus_tavg-u-hxy-u upstream "area: time: mean" führt, also genau unseren Wert.

Das ist dieselbe Ursache wie in ESGF/cc-plugin-wcrp#53 (288 von 619 CORDEX-Einträgen zeigen auf nicht existierende branded variables), dort nur für CORDEX beschrieben. Falls hilfreich, stellen wir die Liste der betroffenen branded variables zusammen.

Die 39 `cell_measures` sind dagegen unsere: der Data Request verlangt bei 3D-Ozeanvariablen "`area: areacello volume: volcello`", wir hatten auf "`area: areacello`" gekürzt. Der Grund war, dass der cf-checker in §7.2 nur ein einzelnes Paar akzeptiert, während CF 1.11 §7.2 selbst mehrere erlaubt.

Wir schreiben jetzt den DReq-Wert unverändert, weil das die Variante ist, die am Ende *beide* Checks besteht: ATTR004 verlangt sie schon heute, und `ioos/compliance-checker#1323` macht §7.2 mehrfachpaar-fähig. Bis der PR gemergt ist, tauscht das die 39 ATTR004-Befunde gegen 39 §7.2-Befunde. Kürzen würde ATTR004 dagegen dauerhaft verfehlen, denn der Data Request verlangt beide Paare.

Die §6.1-Befunde auf den Becken-Achsen haben wir aufgeklärt. Der Checker meldete auf `hfbasin` und `sltbasin`:

```
6.1.1 'atlantic_arctic_oceanindian_pacific_oceanglobal_ocean' specified by 'basin'
is not a valid region
```

Die drei Labels laufen zu einem String zusammen. Das ist dieselbe Ursache wie beim `landuse`-Nebenbefund oben: die Koordinate enthielt Python-Strings, `xarray` schrieb eine `NC_STRING`-Variable, und der Checker liest die Achse dann als einen einzigen Wert statt als drei. Jedes Label für sich ist im CV gültig. Wir schreiben die Achse jetzt als `char sector(basin, strlen)`, mit `standard_name = region` und `long_name = "Ocean Basin"` aus dem CMIP7-CV, geprüft gegen publizierte MPI-ESM1-2-LR-Dateien (`Omon.hfbasin`). In `cli111` ist davon noch einer übrig, der zum **upstream-HIGH** auf der `basin-fx`-Datei gehört.

Ein weiteres Beispiel derselben Sorte: für `seaIce.sivol.tavg-u-hm-u.day.sh` erwartet die Registry "Sea-Ice Volume North", während die DReq-Tabelle "Sea-Ice Volume South" vorgibt. Denselben Befund gab es schon in `cli108`.

6 Offene Frage an dich

Nur `mrsol` wurde ursprünglich von Hand geprüft, weil dein Review darauf zeigte. Unsere Nachsuche hat eine Stichprobe abgedeckt, nicht alles. Andere Variablen, die sich einen Stream über mehrere DReq-Einträge teilen, könnten dieselbe Fehlerklasse haben, und sie ist für QC unsichtbar. Wir planen vor der Publikation einen Durchlauf, der für jede Regel `compound_name` gegen `operation` und Felddefinition des gelesenen Streams prüft. Falls es so etwas schon gibt oder bei DKRZ geplant ist, wäre das gut zu wissen.